EnergyWatch AI

GOUVERNANCE

Agent Card

Fiche système et fiche de chaque agent : rôle, outils, permissions, autonomie, supervision humaine, modes de défaillance et limites.

Projet	**EnergyWatch AI, plateforme multi-agents (LangGraph)**
Secteur	**Énergie**
Cadre	**Mini-projet S5 · Agent en production**
Version	**1.2.0**
Date	**30 octobre 2026**
Dépôt	**github.com/bouincha/Energy-Watch-AI**

Agent Card : EnergyWatch AI

> **Source de référence :** `app/governance/agent_cards.json`, exposé en direct sur `GET /api/agent-card` et affiché sur la page **Governance** du tableau de bord. **Toujours à jour :** le test `tests/test_governance_eval.py` échoue dans la CI si un agent du graphe n'a pas de carte, si une carte ne correspond à aucun agent, si un champ obligatoire manque, si une carte cite un outil inconnu ou si sa version diffère de celle de l'application.

Fiche système

Champ	Valeur
Nom	EnergyWatch AI
Version	1.2.0 (alpha, pilote en production)
Dernière mise à jour	30/10/2026
Secteur	Énergie
Architecture	Modèle superviseur LangGraph : guardrails → superviseur → spécialistes → report_writer → monitor
Fournisseurs LLM	Groq, Gemini, OpenAI, Anthropic, simulateur déterministe (mock)
Version des prompts	`2026.10.1` (`app/agents/prompts.py`)
SLO	Latence de bout en bout ≤ 8 000 ms · taux d'erreur/dégradé ≤ 20 % · disponibilité 99 %
Responsable	Équipe EnergyWatch AI (contact : issues GitHub)

Usages prévus

- Répondre aux questions des gestionnaires d'énergie sur la consommation, le coût, le CO_2 et les pics
- Détecter et expliquer les consommations anormales (fuites, horaires, dérives, pannes)
- Recommander des actions d'efficacité énergétique fondées sur une base documentaire validée
- Soumettre les actions proposées à une validation humaine, avec une piste d'audit complète

Hors périmètre

- Le pilotage direct des équipements (le système est en lecture seule sur l'infrastructure)
- Les décisions critiques en zone clinique sans le responsable de l'établissement
- Le conseil financier ou contractuel sur les contrats d'électricité
- Les questions sans rapport avec l'énergie (bloquées par les guardrails)

Risques et mesures (OWASP Top 10 pour les applications LLM)

Risque	Mesure
LLM01 Injection de prompt	Filtre d'entrée par motifs avant tout appel au LLM ; incident RB-003 en cas de rafale
LLM02 Divulgation d'informations sensibles	Contrôle des réponses (identifiants) ; masquage des données personnelles dans les logs ; aucun secret dans les prompts
LLM06 Autonomie excessive	Outils en lecture seule ; validation humaine des actions à risque moyen/élevé ; piste d'audit
LLM09 Chiffres inventés	Les chiffres viennent d'outils déterministes ; les prompts interdisent d'inventer ; citations des sources
LLM10 Consommation non maîtrisée	Limite de longueur, limitation du débit par client, délais d'expiration, disjoncteur
Panne du fournisseur LLM	Nouvelles tentatives + disjoncteur + mode dégradé déterministe (RB-001)

Fiches des agents

1. Agent Guardrails (`guardrails`) · v1.2.0 · déterministe

- **Rôle :** porte de sécurité.
- **Fonction :** vérifie chaque question : motifs d'injection de prompt, longueur (≤ 1 000 caractères), caractères de contrôle cachés et sujet (énergie uniquement).
- **Outils :** aucun · **Permissions :** aucune (fonction pure).
- **Supervision humaine :** les requêtes bloquées apparaissent dans l'explorateur d'exécutions (`status=blocked`) et dans le journal d'audit.
- **Modes de défaillance :** faux positifs sur une formulation inhabituelle ; injection nouvelle non couverte par les motifs.
- **Limites :** basé sur des expressions régulières, ne détecte pas les injections déguisées sémantiquement.
- **Métriques :** `energywatch_guardrail_blocks_total{category}` .

2. Agent Superviseur / Planificateur (`supervisor`) · v1.2.0 · LLM

- **Rôle :** routage et planification.
- **Fonction :** classe l'intention (consommation, anomalie, conseil, rapport), détecte le site et la période, et planifie les spécialistes grâce à une **sortie structurée** validée par Pydantic (`RoutingDecision`).
- **Assainissement de la sortie :** agents autorisés uniquement, sans doublon et ordonnés ; identifiants de site valides ; 1 à 30 jours.
- **Repli :** planificateur déterministe par mots-clés (utilisé aussi en mode mock).
- **Supervision humaine :** le plan et son raisonnement sont affichés avec chaque réponse.
- **Limites :** un seul site par question.

3. Agent Analyste de consommation (`consumption_analyst`) · v1.2.0 · LLM

- **Rôle :** analyse de données avec **appel d'outils** (tool calling).
- **Outils :** `get_consumption_summary` , `compare_periods` , `get_top_consumers` , `get_data_center_pue` (lecture seule, arguments validés).
- **Repli :** choix d'outils par règles et texte généré par modèle. Les erreurs d'outil déclenchent RB-004.
- **Limites :** granularité horaire ; 30 jours d'historique.

4. Agent Détecteur d'anomalies (`anomaly_detector`) · v1.2.0 · LLM pour l'explication uniquement

- **Rôle :** détection et explication.
- **Outils :** `detect_anomalies` (z-score robuste par rapport à une référence par heure et par type de jour).
- **Sortie :** événements avec motif, durée, kWh excédentaires, coût et gravité, plus les causes probables.
- **Qualité :** précision 1,00 / rappel 1,00 sur les anomalies injectées (voir la documentation technique).
- **Limites :** la référence doit être réapprise après un changement structurel sur un site.

5. Agent Conseiller énergie (`energy_advisor`) · v1.2.0 · LLM + RAG

- **Rôle :** recommandations fondées sur des sources et propositions d'actions.
- **Outils :** `knowledge_base.search` (BM25), `detect_anomalies` , `actions.propose` .
- **Permissions :** peut **proposer** des actions, jamais les exécuter.
- **Politique d'autonomie :** risque faible = approuvé automatiquement ; risque moyen ou élevé = en attente d'une personne.
- **Supervision humaine :** Approuver ou Rejeter depuis la page Approvals ou directement dans le chat ; chaque décision est auditée.
- **Limites :** base de 7 documents ; les économies sont des estimations.

6. Agent Rédacteur du rapport (`report_writer`) · v1.2.0 · LLM

- **Rôle :** synthèse de la réponse finale.
- **Fonction :** assemble les résultats des spécialistes en Markdown en conservant chaque chiffre et chaque citation, signale le mode dégradé et applique le filtre de sortie (masquage des identifiants).
- **Repli :** rapport généré par modèle à partir des sections des spécialistes.

7. Agent de Monitoring (`monitor`) · v1.2.0 · déterministe

- **Rôle :** observabilité, SLO et détection d'incidents.
- **Fonction :** enveloppe chaque agent pour enregistrer des « spans » liés au correlation ID, évalue chaque exécution par rapport aux SLO, met à jour les métriques Prometheus et ouvre ou résout les incidents (RB-001 à RB-004).
- **Permissions :** écriture dans les stockages de télémétrie uniquement.
- **Limites :** stockage en mémoire (une seule instance). Les logs JSON constituent la trace durable.

Politique de versionnement

- La **version du système** (`app/__init__.py`), les **versions des fiches** et la **version des prompts** (`app/agents/prompts.py`) évoluent ensemble et sont consignées dans `CHANGELOG.md`.
- Toute modification d'un prompt, d'une liste d'outils ou de la politique d'autonomie impose la mise à jour de la fiche ; le test de la CI le vérifie.